

Section 6. 경사 하강 심화 이론 (Advanced Topics in Gradient Descent)

목차

- 섹션 0. 강의 소개
- 섹션 1. PyTorch 환경 설정
- 섹션 2. 딥러닝이란?
- 섹션 3. 손실 함수 (Loss Function)
- 섹션 4. 손실 함수에 대한 심화 이론 (Advanced Topics on Loss Function)
- 섹션 5. 경사 하강 (Gradient Descent)
- 섹션 6. 경사 하강에 대한 심화 이론 (Advanced Topics on Gradient Descent)

Recap from Section 5. Gradient Descent의 기본 개념

Recap

Section 5. Gradient Descent의 기본 개념

Gradient Descent

역할: 손실 함수의 값이 **최소화**하도록 모델의 **weight**을 **최적화**하는 것

원리:

- 경사는 손실함수가 증가하는 방향을 향한다.
- 따라서 경사하강은 경사의 음의 방향으로 모델의 weight를 update해주는 것이다!


$$w \rightarrow w - \lambda \cdot \frac{dL}{dw}$$

Recap

Section 5. Gradient Descent의 기본 개념

- 하지만 이것은 variable이 하나인 (single variate input)의 간단한 예시였다.


$$w \rightarrow w - \lambda \cdot \frac{dL}{dw}$$



Recap

Extending from single variate to multi-variate


- 하지만 Input feature가 여러 개 (multi-variate)하거나 Hidden layer가 여러개의 neuron들로 구성되어 있으면 어떻게 할 것인가?



Recap

Extending from single variate to multi-variate

- 이번 시간에는 아래와 같은 Multi-variate의 경우에 대해서 살펴보자!



Multi variate

6-1. Multi-variate Multi neuron Neural Network

Objective



학습 목표

- Scalar input, single neuron으로 구성된 Neural Network을 Multi variate, Multi neuron으로 확장하기
- Neural Network의 forward pass을 행렬의 곱으로 표현하기

Multi-variate Multi-neuron NN

- 여러 개의 뉴론들 $W \in \mathbb{R}^{M \times D}$ 로 구성된 **Layer**들이 여러 개 쌓여있고,
- 입력값이 다차원의 **vector** $\mathbf{x} \in \mathbb{R}^D$


앞에서 고려한 매우 단순한 뉴럴넷 예제



Multi-variate Multi-neuron NN

Multivariate Case

- 예를 들어 **ResNet-50**의 경우 23 million (2300만개의 **weight parameter**)들로 구성 됨.
- 통상적으로 input도 scalar 값이 아니라 다차원의 vector이다. (**multivariate**)
- 어떻게 하면:




Single Variable, Single Neuron Neural Network Forward Pass

Multi-variate Multi-neuron NN

Single variate, Single Neuron의 경우

앞에서 고려한 매우 단순한 뉴럴넷 예제




일단 편의상 Activation Function은 생략

Multi-variate Multi-neuron NN

Single variate, Single Neuron의 경우

앞에서 고려한 매우 단순한 뉴럴넷 예제



- Input \rightarrow Hidden

$$h_1 = w_1 x$$

- Hidden \rightarrow Output

$$\hat{Y} = w_2 h_1$$


- Output \rightarrow Loss

$$L = L(Y, \hat{Y})$$

Multi-variate Multi-neuron NN

Single variate, Single Neuron의 경우

앞에서 고려한 매우 단순한 뉴럴넷 예제



- Input \rightarrow Hidden

$$h_1 = w_1 x$$

- Hidden \rightarrow Output

$$\hat{Y} = w_2 h_1$$

- Output \rightarrow Loss


$$L = L(Y, \hat{Y})$$

단순히 scalar의 곱이다!

Multivariate Multi-Neuron Neural Network Forward Pass

Multi-variate Multi-neuron NN


Multi variate, Multi Neuron의 경우



Multi-variate, Multi-neuron에 대해서는
forward pass을 어떻게 계산할까?

Multi-variate Multi-neuron NN

Multi variate, Multi Neuron의 경우



Multi-variate, Multi-neuron에 대해서는
forward pass을 어떻게 계산할까?

결론부터 먼저 말하면:

행렬의 곱 (Matrix Multiplication)

으로 표현할 수 있다!

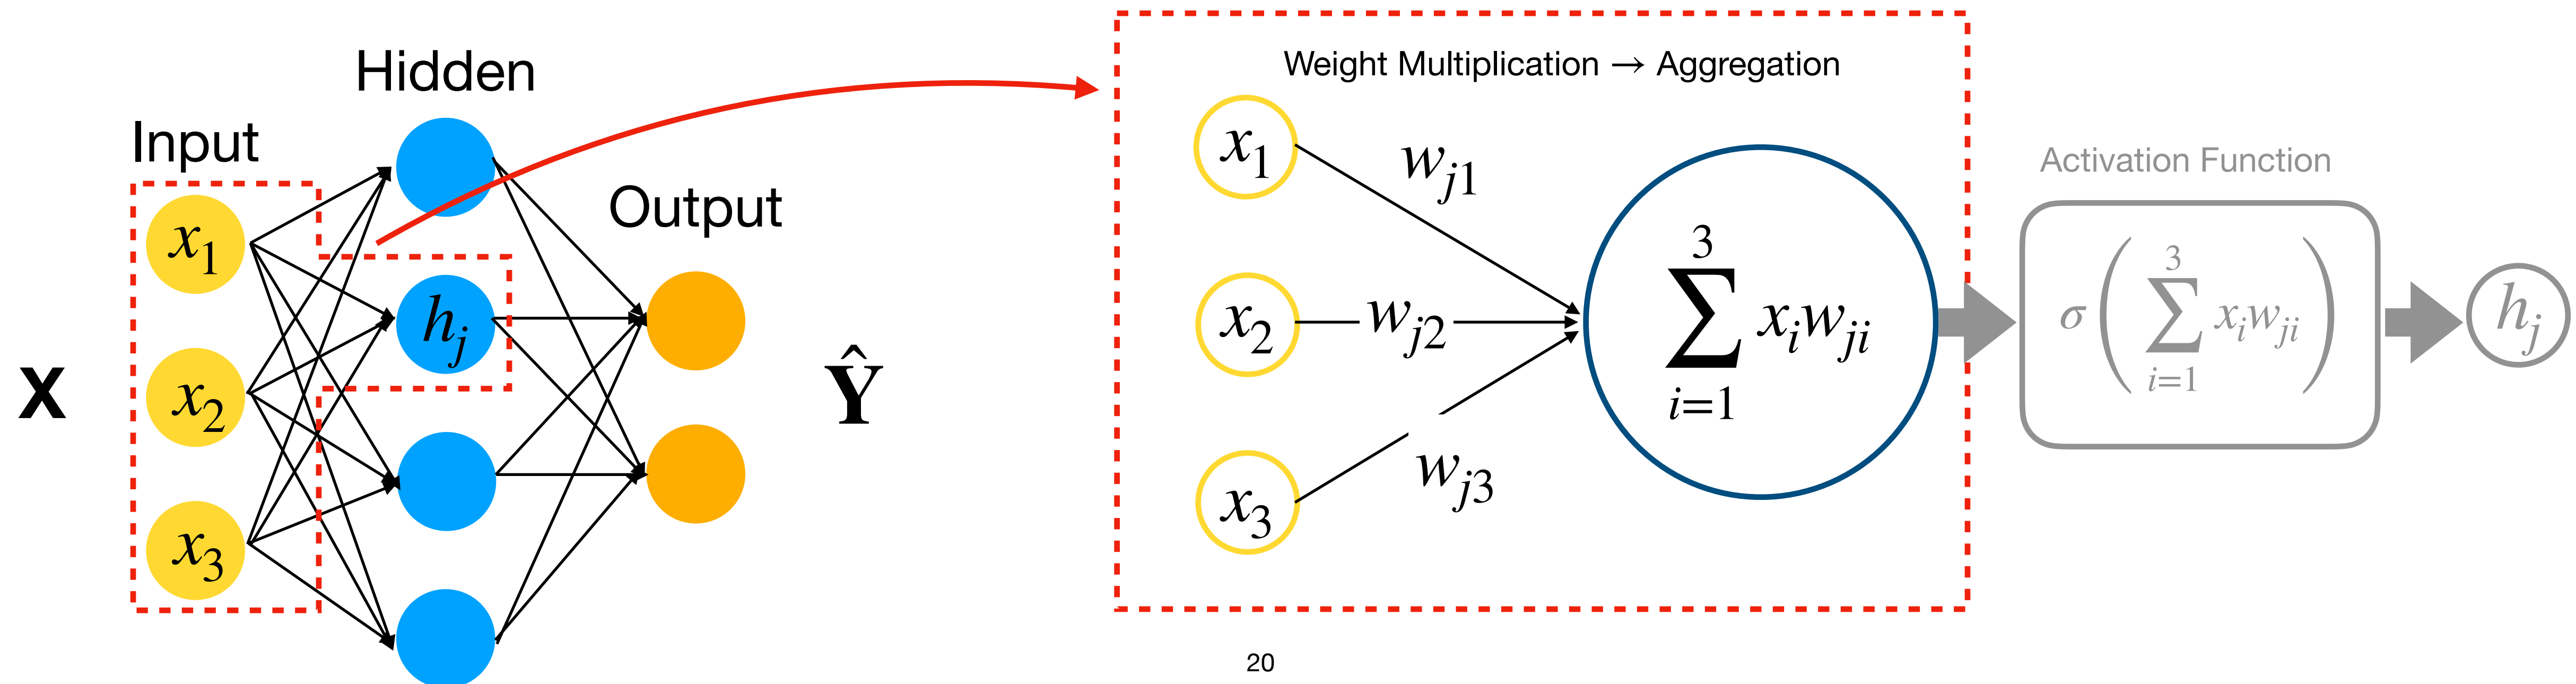
왜 그렇게 되는지 살펴보자!

Recap from Section 2

Recap from Section 2


- (일단 편의상 Activation Function에 대해서는 생략)

- $\sum_{i=1}^3 x_i w_{ji}$: 이전 Layer의 출력값 x_i 은 **가중치 w_{ji} 에 곱해져서 합해진다.** (weight multiplication → aggregation)



Recap from Section 2

- 참고로 w_{ji} 에서
 - j 은 현재 Hidden layer에서 j 번째 뉴런을 의미
 - i 은 이전 layer에서 i 번째 뉴런을 의미



Forward Pass as Matrix Multiplication

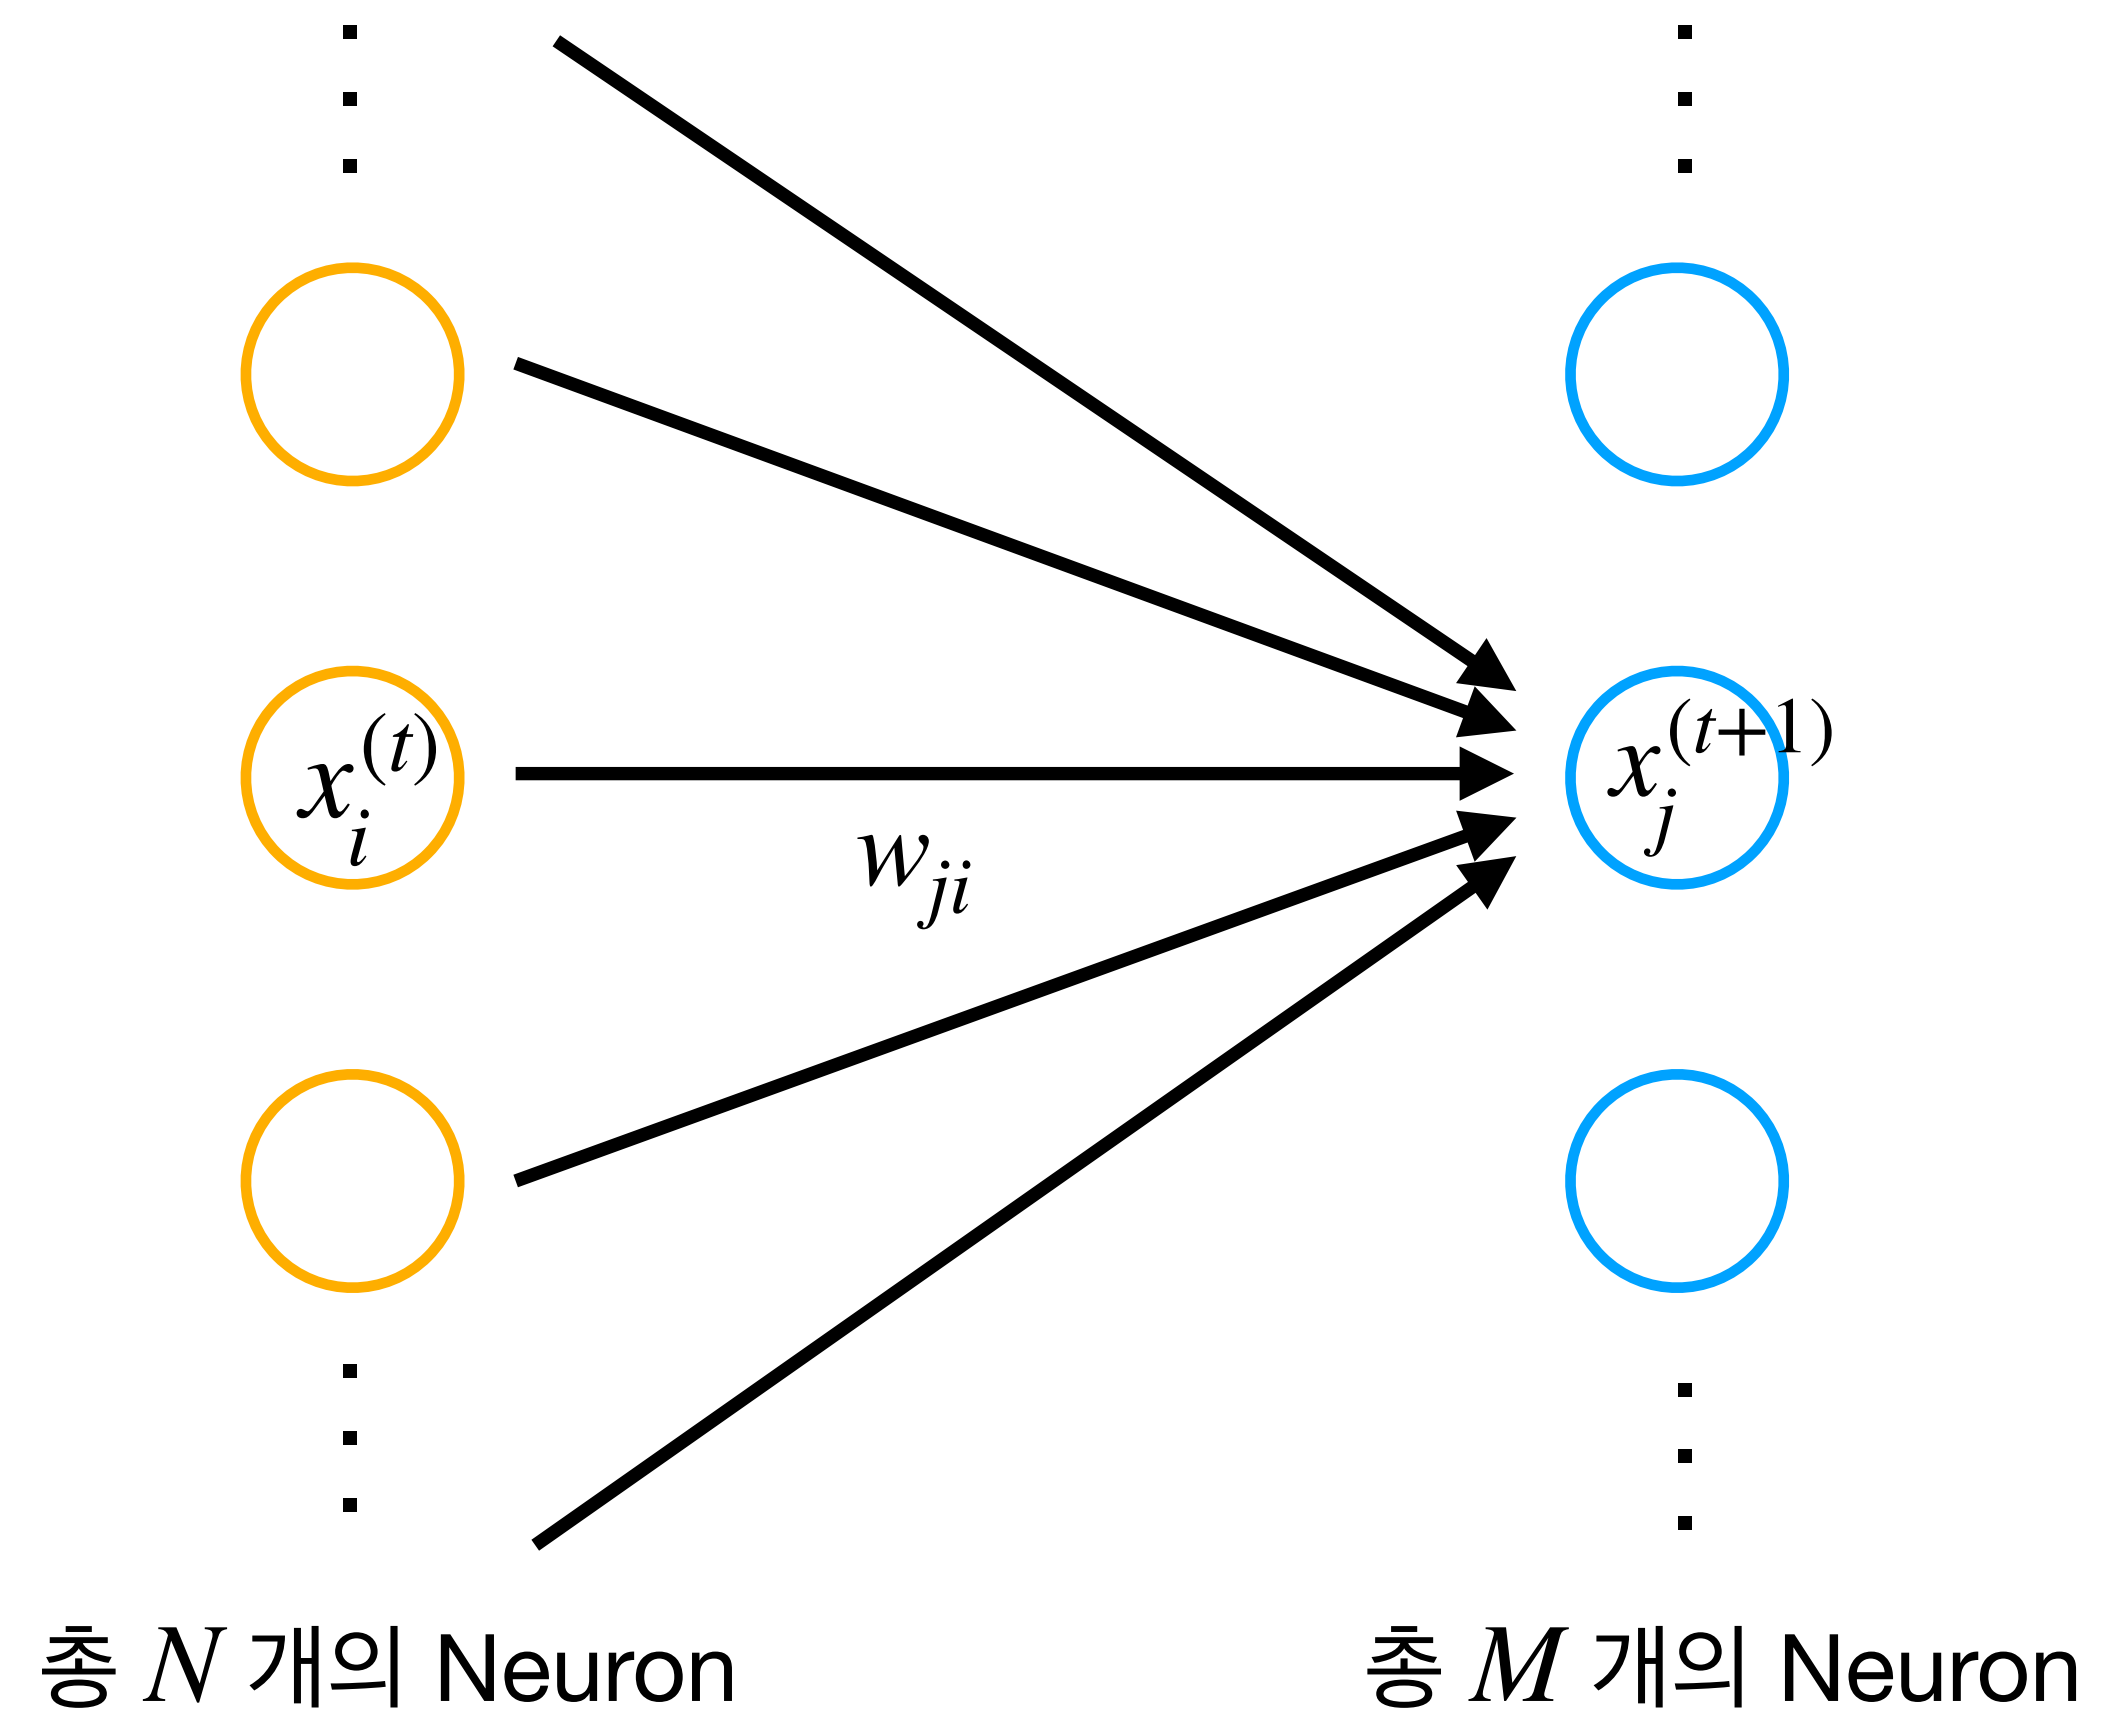
Forward Pass

$$x_j^{(t+1)} = \sum_{i=1}^N w_{ji} x_i^{(t)}$$

$$= w_{j1}x_1 + w_{j2}x_2 + \dots + w_{jN}x_N$$

t 번째 Hidden Layer

$t + 1$ 번째 Hidden Layer



Forward Pass

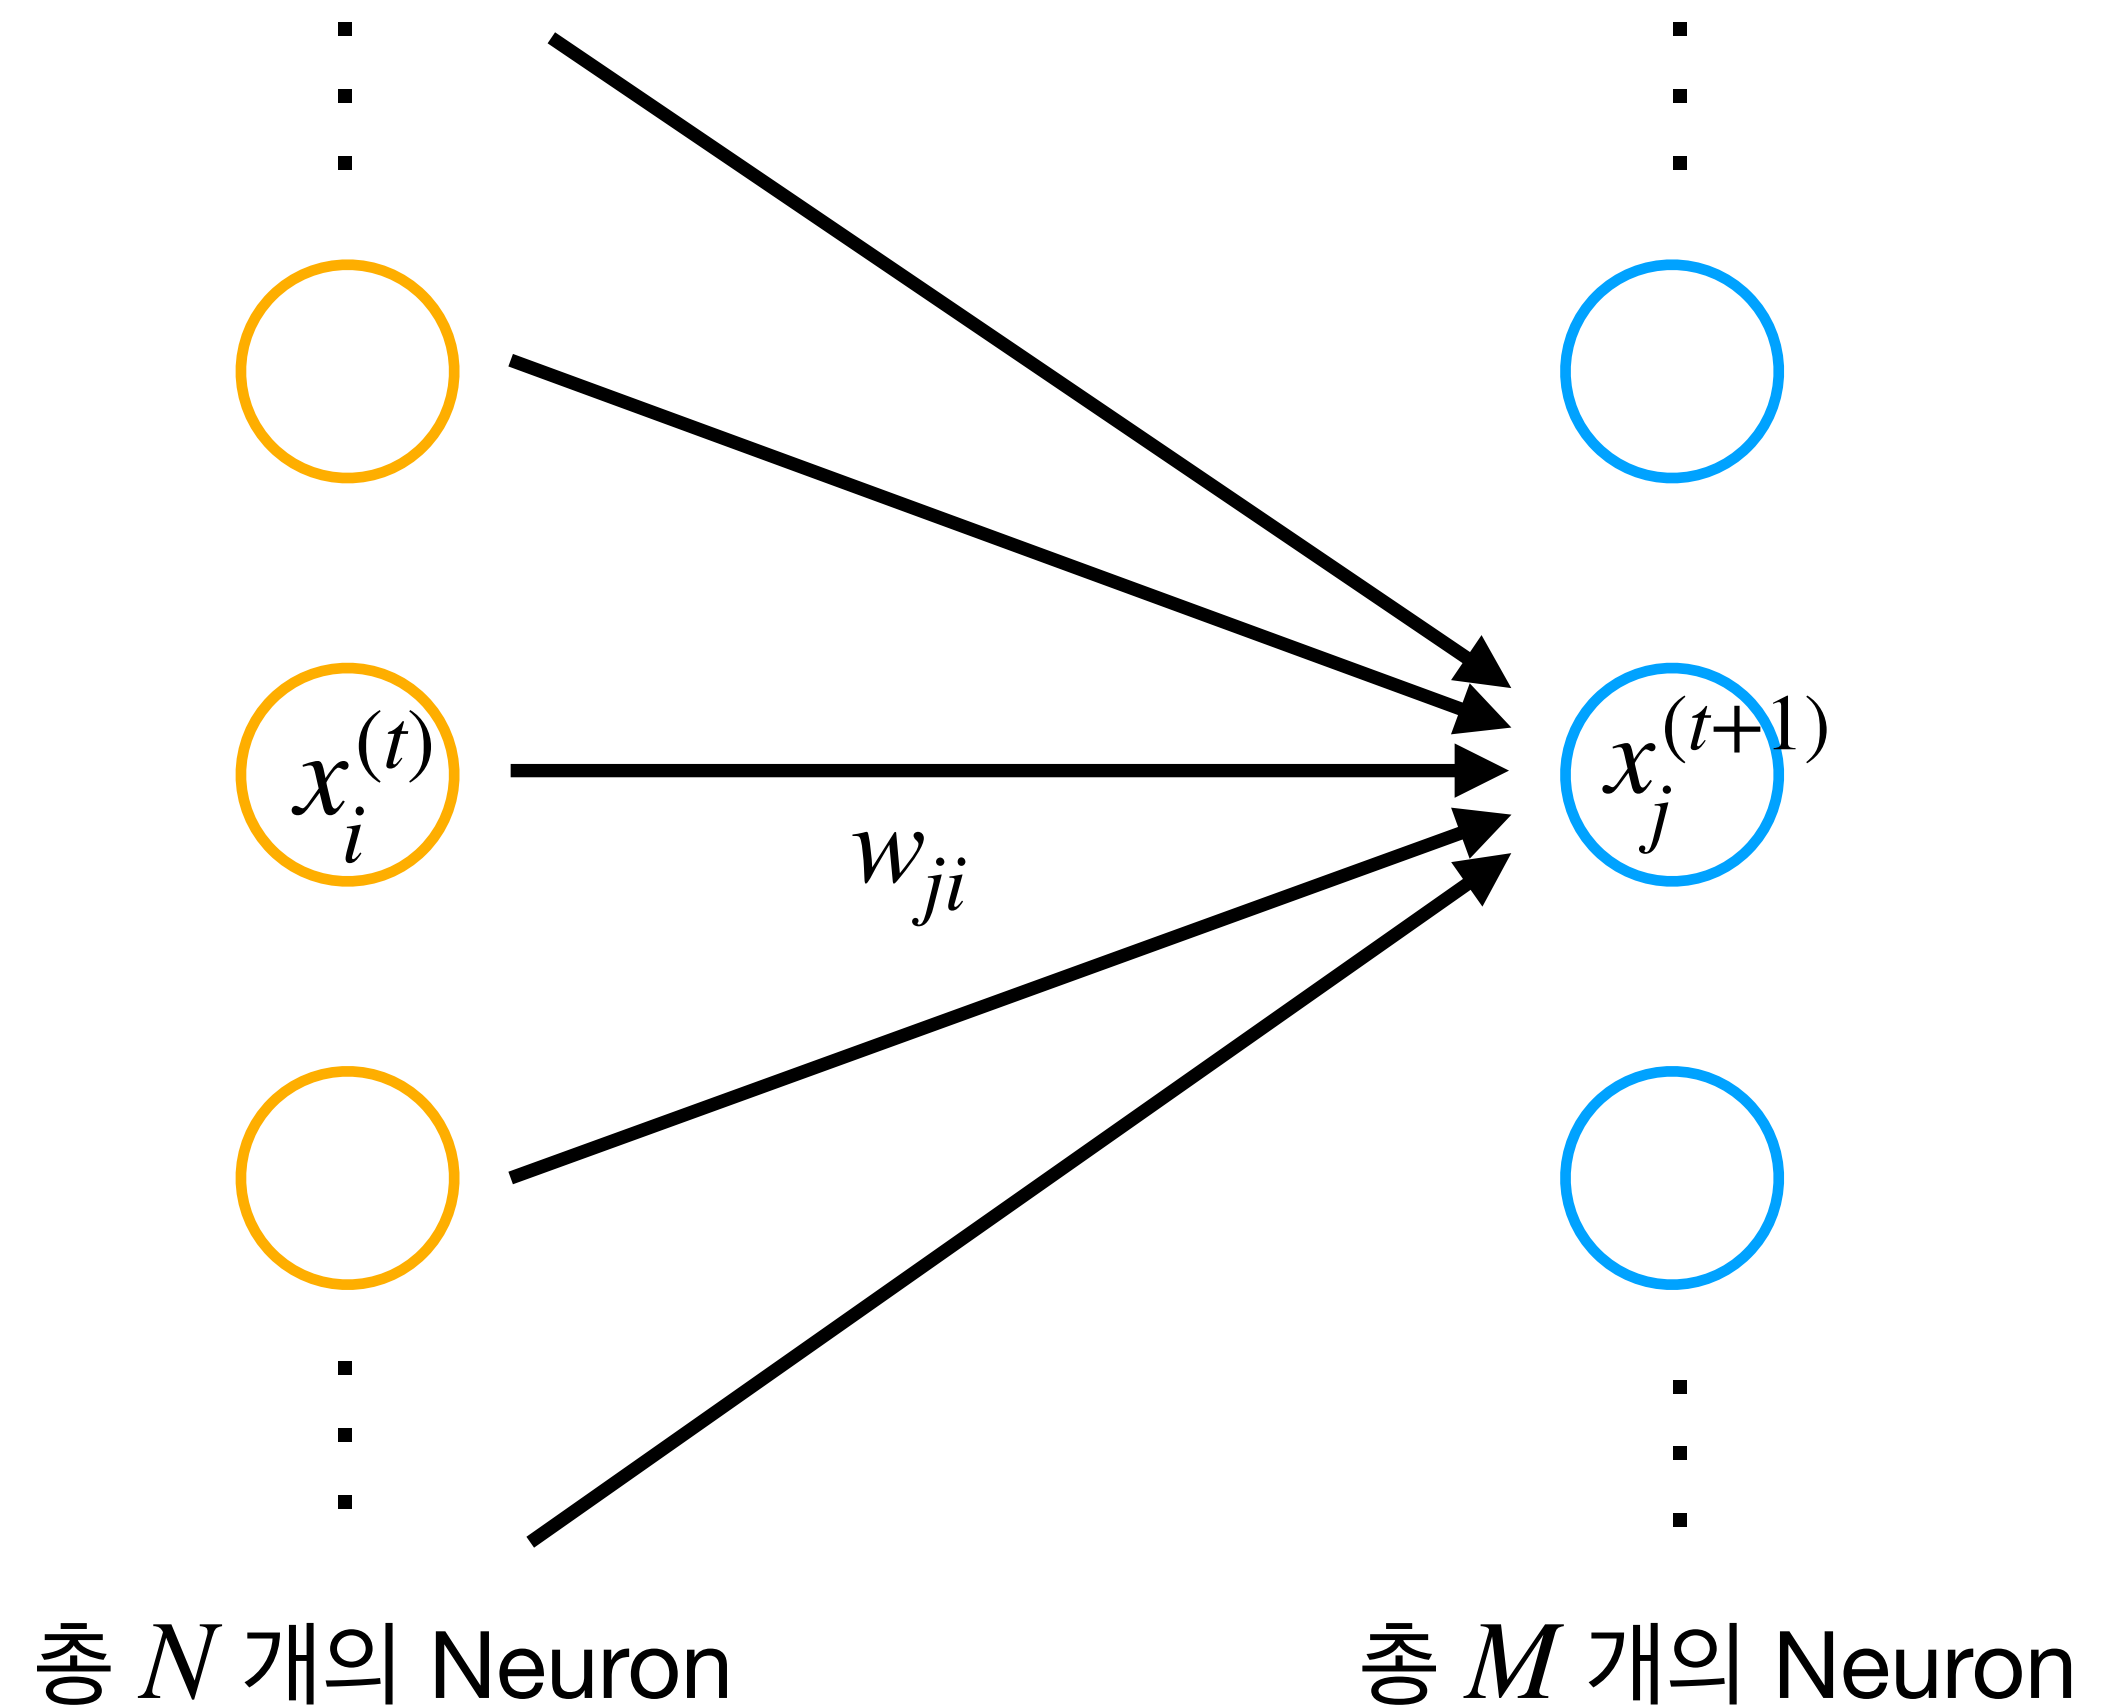
$$x_j^{(t+1)} = \sum_{i=1}^N w_{ji} x_i^{(t)}$$

$$= w_{j1}x_1 + w_{j2}x_2 + \cdots + w_{jN}x_N$$

Vector의 내적으로 표현할 수 있다!

t 번째 Hidden Layer

$t + 1$ 번째 Hidden Layer



Forward Pass

행렬의 곱 Recap

$$(w_{j1} \quad \dots \quad w_{ji} \quad \dots \quad w_{jN}) \begin{pmatrix} x_1^{(t)} \\ \dots \\ x_i^{(t)} \\ \dots \\ x_N^{(t)} \end{pmatrix} = w_{j1}x_1^{(t)} + \dots + w_{ji}x_i^{(t)} + \dots + w_{jN}x_N^{(t)}$$

Forward Pass

행렬의 곱 Recap

$$\begin{pmatrix} w_{j1} & \dots & w_{ji} & \dots & w_{jN} \end{pmatrix} \begin{pmatrix} x_1^{(t)} \\ \dots \\ x_i^{(t)} \\ \dots \\ x_N^{(t)} \end{pmatrix} = w_{j1}x_1^{(t)} + \dots + w_{ji}x_i^{(t)} + \dots + w_{jN}x_N^{(t)}$$

Forward Pass

행렬의 곱 Recap

$$\begin{pmatrix} w_{j1} & \cdots & w_{ji} & \cdots & w_{jN} \end{pmatrix} \begin{pmatrix} x_1^{(t)} \\ \vdots \\ x_i^{(t)} \\ \vdots \\ x_N^{(t)} \end{pmatrix} = w_{j1}x_1^{(t)} + \cdots + w_{ji}x_i^{(t)} + \cdots + w_{jN}x_N^{(t)}$$

Forward Pass

행렬의 곱 Recap

$$\begin{pmatrix} w_{j1} & \dots & w_{ji} & \dots & w_{jN} \end{pmatrix} \begin{pmatrix} x_1^{(t)} \\ \dots \\ x_i^{(t)} \\ \dots \\ x_N^{(t)} \end{pmatrix} = w_{j1}x_1^{(t)} + \dots + w_{ji}x_i^{(t)} + \dots + w_{jN}x_N^{(t)}$$

Forward Pass

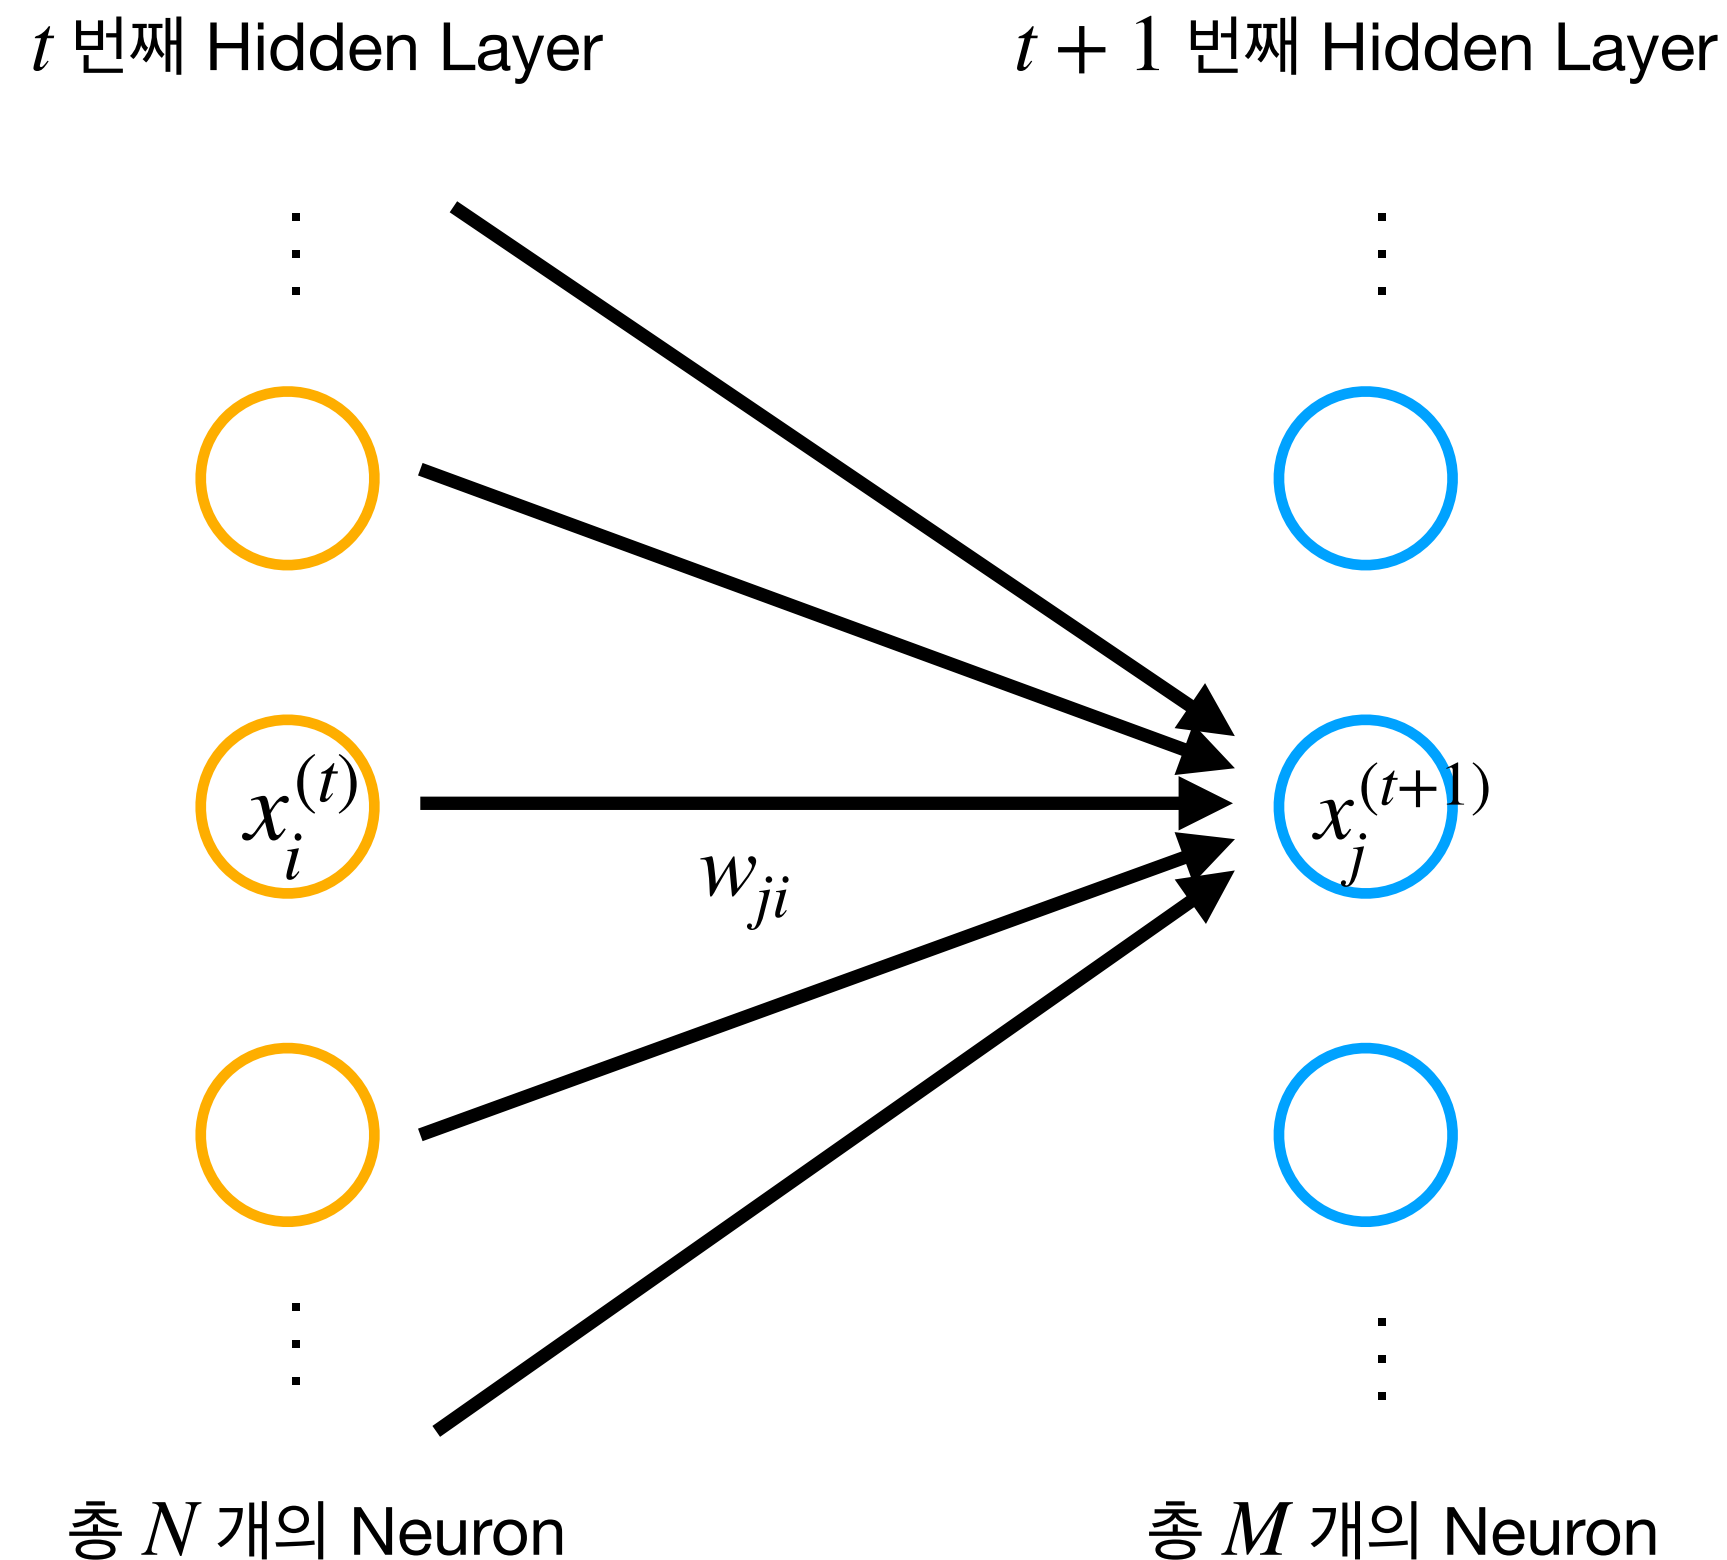
행렬의 곱 Recap

$$\begin{pmatrix} w_{j1} & \dots & w_{ji} & \dots & w_{jN} \end{pmatrix} \begin{pmatrix} x_1^{(t)} \\ \dots \\ x_i^{(t)} \\ \dots \\ x_N^{(t)} \end{pmatrix} = w_{j1}x_1^{(t)} + \dots + w_{ji}x_i^{(t)} + \dots + w_{jN}x_N^{(t)} \\
 = \sum_{i=1}^N w_{ji}x_i^{(t)}$$

Forward Pass

행렬의 곱 Recap

이것은 $t+1$ 번째 Hidden layer에서 j 번째 neuron에 해당된다.
나머지 1~ M 개의 neuron에 대해서도 확장해보자!



$$(w_{j1} \quad \dots \quad w_{ji} \quad \dots \quad w_{jN})$$

$$\begin{pmatrix} x_1^{(t)} \\ \dots \\ x_i^{(t)} \\ \dots \\ x_N^{(t)} \end{pmatrix} = \sum_{i=1}^N w_{ji} x_i^{(t)} = x_j^{(t+1)}$$


Forward Pass

행렬의 곱 Recap

$$\mathbf{x}^{(t+1)} = W\mathbf{x}^{(t)}$$

t 번째 Hidden Layer

$t + 1$ 번째 Hidden Layer




Forward Pass

행렬의 곱 Recap

$$\mathbf{x}^{(t+1)} = W\mathbf{x}^{(t)}$$

t 번째 Hidden Layer

$t + 1$ 번째 Hidden Layer



$$\begin{pmatrix} w_{11} & \dots & w_{1i} & \dots & w_{1N} \\ w_{j1} & \dots & w_{ji} & \dots & w_{jN} \\ w_{M1} & \dots & w_{Mi} & \dots & w_{MN} \end{pmatrix}$$

$$W \in \mathbb{R}^{M \times N}$$

$$\begin{pmatrix} x_1^{(t)} \\ \dots \\ x_i^{(t)} \\ \dots \\ x_N^{(t)} \end{pmatrix}$$

$$\mathbf{x}^{(t)} \in \mathbb{R}^N$$

$$= \begin{pmatrix} \sum_{i=1}^N w_{1i}x_i^{(t)} \\ \dots \\ \sum_{i=1}^N w_{ji}x_i^{(t)} \\ \dots \\ \sum_{i=1}^N w_{Mi}x_i^{(t)} \end{pmatrix}$$

$$= \begin{pmatrix} x_1^{(t+1)} \\ \dots \\ x_j^{(t+1)} \\ \dots \\ x_N^{(t+1)} \end{pmatrix}$$

$$\mathbf{x}^{(t+1)} \in \mathbb{R}^M$$


Forward Pass

행렬의 곱 Recap

$$\mathbf{x}^{(t+1)} = W\mathbf{x}^{(t)}$$

t 번째 Hidden Layer

$t + 1$ 번째 Hidden Layer



$$\begin{pmatrix} w_{11} & \dots & w_{1i} & \dots & w_{1N} \\ \vdots & & \vdots & & \vdots \\ w_{j1} & \dots & w_{ji} & \dots & w_{jN} \\ \vdots & & \vdots & & \vdots \\ w_{M1} & \dots & w_{Mi} & \dots & w_{MN} \end{pmatrix}$$

$$W \in \mathbb{R}^{M \times N}$$

$$\begin{pmatrix} x_1^{(t)} \\ \vdots \\ x_i^{(t)} \\ \vdots \\ x_N^{(t)} \end{pmatrix}$$

$$\mathbf{x}^{(t)} \in \mathbb{R}^N$$

$$= \begin{pmatrix} \sum_{i=1}^N w_{1i}x_i^{(t)} \\ \vdots \\ \sum_{i=1}^N w_{ji}x_i^{(t)} \\ \vdots \\ \sum_{i=1}^N w_{Mi}x_i^{(t)} \end{pmatrix}$$

$$= \begin{pmatrix} x_1^{(t+1)} \\ \vdots \\ x_j^{(t+1)} \\ \vdots \\ x_N^{(t+1)} \end{pmatrix}$$


$$\mathbf{x}^{(t+1)} \in \mathbb{R}^M$$

Forward Pass

$$(w_{j1} \quad \dots \quad w_{ji} \quad \dots \quad w_{jN}) \begin{pmatrix} x_1^{(t)} \\ \vdots \\ x_i^{(t)} \\ \vdots \\ x_N^{(t)} \end{pmatrix} = x_j^{(t+1)}$$

정리하자면:


$$x_j^{(t+1)} = \sum_{i=1}^N w_{ji} x_i^{(t)}$$



Forward Pass

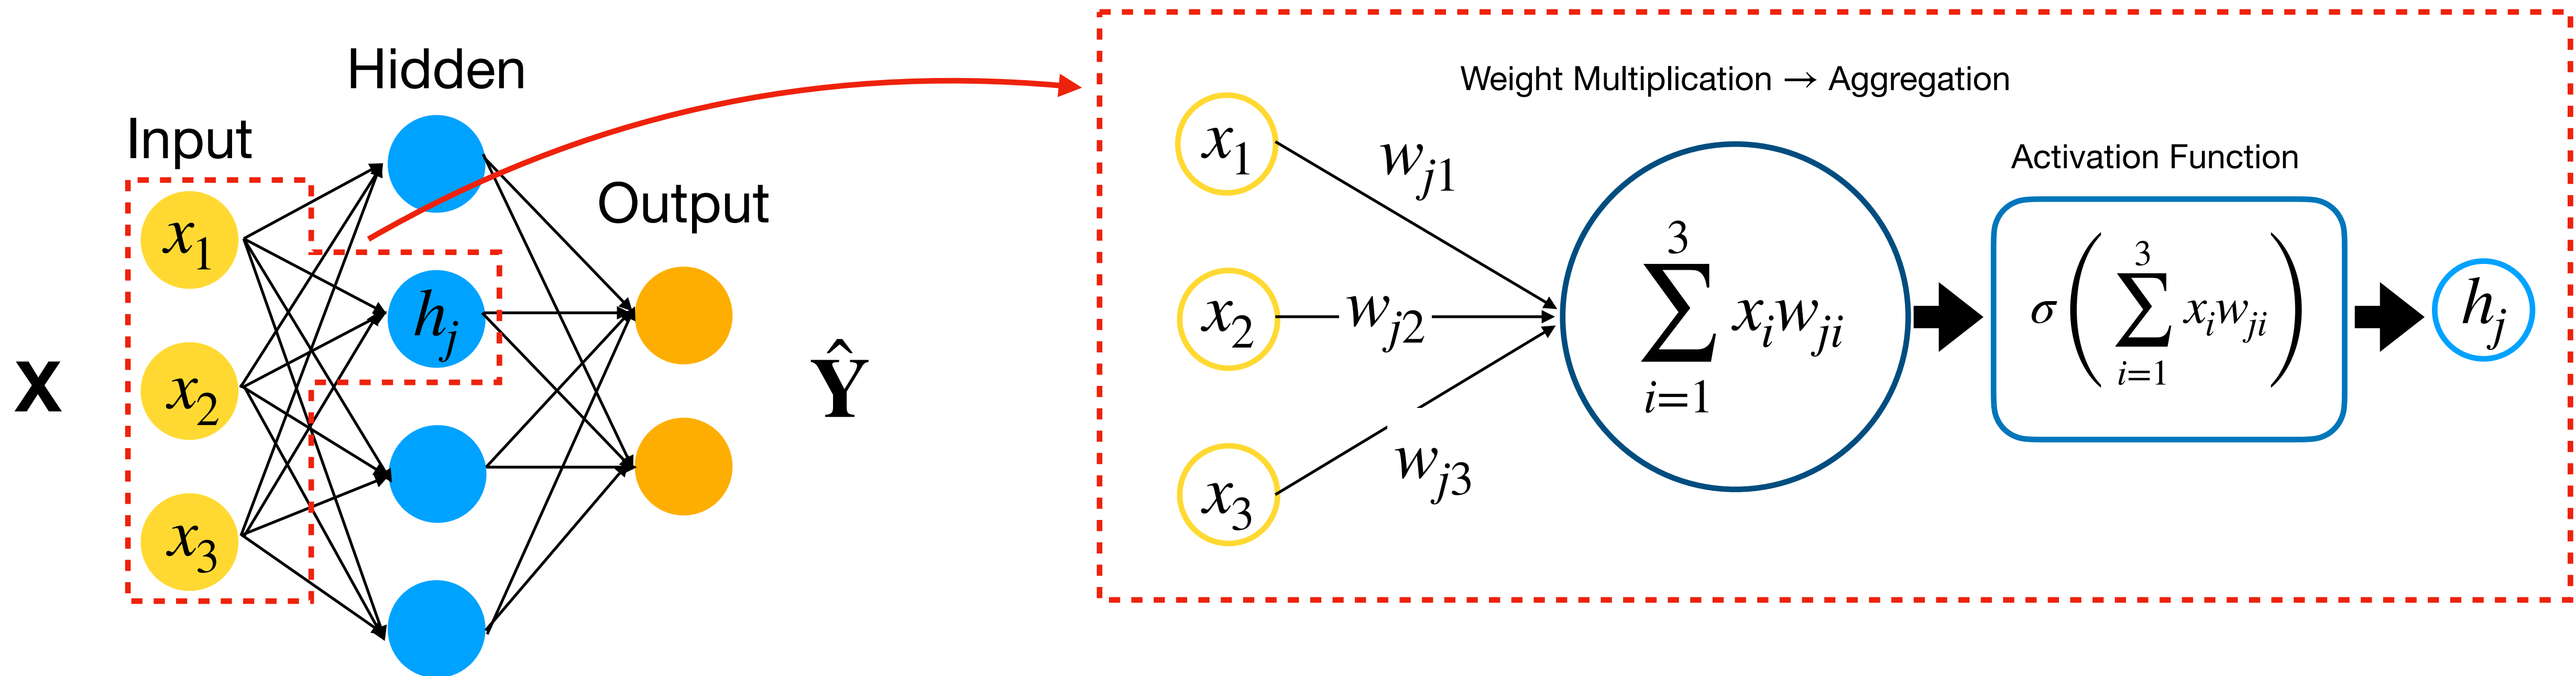
t 번째 Hidden Layer

$t + 1$ 번째 Hidden Layer



즉, (Activation function이 제외된) Neural Network은 단순히 matrix의 곱이다!

$$\mathbf{x}^{(t+1)} = W\mathbf{x}^{(t)}$$



만약에 Activation Function을 포함한다면,

$$\mathbf{h} = \sigma(W\mathbf{x})$$

Activation Function도 포함하는 경우

$$x_j^{(t+1)} = \sigma \left(\sum_{i=1}^N w_{ji} x_i^t \right) \rightarrow \mathbf{X}^{(t+1)} = \sigma \left(W \mathbf{X}^{(t)} \right)$$

Weight Matrix

$$\sigma \left(\begin{pmatrix} w_{11} & \dots & w_{1i} & \dots & w_{1N} \\ \vdots & & \vdots & & \vdots \\ w_{j1} & \dots & w_{ji} & \dots & w_{jN} \\ \vdots & & \vdots & & \vdots \\ w_{M1} & \dots & w_{Mi} & \dots & w_{MN} \end{pmatrix} \right)$$

Input vector

$$\begin{pmatrix} x_1^{(t)} \\ \vdots \\ x_i^{(t)} \\ \vdots \\ x_N^{(t)} \end{pmatrix}$$

$$=$$

$$\begin{pmatrix} \sigma \left(\sum_{i=1}^N w_{1i} x_i^{(t)} \right) \\ \vdots \\ \sigma \left(\sum_{i=1}^N w_{ji} x_i^{(t)} \right) \\ \vdots \\ \sigma \left(\sum_{i=1}^N w_{Mi} x_i^{(t)} \right) \end{pmatrix}$$

$$=$$

Output vector

$$\begin{pmatrix} x_1^{(t+1)} \\ \vdots \\ x_j^{(t+1)} \\ \vdots \\ x_M^{(t+1)} \end{pmatrix}$$